

XML

M. KASSE

Université Alioune DIOP de BAMBEY

youssou.kasse@uadb.edu.sn

MASTER 2 SIR

2014 2015

Chapitre 3

La validation des documents XML: DTD

Structure physique : DTD

- Une DTD (Document Type Definition) est une sorte d'entité contenant une description formelle de la structure et du vocabulaire (noms de type d'éléments et noms d'attributs) d'un document.
- La spécification XML définit complètement l'écriture des DTD,
- Mais une DTD n'est pas elle-même un document XML

Structure physique : DTD

- Un processeur validateur lit la DTD avant de lire le document.
- Une DTD
 - Permet de définir le "vocabulaire" et la structure qui seront utilisés dans le document XML
 - Grammaire du langage dont les phrases sont des documents XML (instances)
 - Peut être mise dans un fichier et être appelée dans le document XML

Structure physique : DTD

- La DTD utilise la déclaration DOCTYPE qui référence des déclarations soit internes ou externes
- **DTD interne :**
 - Les déclarations de la DTD sont placés dans le DOCTYPE après la déclaration XML
 - L'attribut standalone a la valeur "yes" `<?xml version="1.0" standalone="yes">`
 - `<!DOCTYPE document [déclarations]> <document > ... </document >`
 - document : nom de la balise racine du document déclaré,
 - déclarations : déclarations d'éléments, d'attributs et d'entités...

Structure physique : DTD

- **DTD externe** : permet d'inclure des documents XML identifiés par une URI
- `<!DOCTYPE document SYSTEM "uri">`
- Les déclarations sont placés dans un fichier séparé
- L'attribut standalone a la valeur "no"
- `<!DOCTYPE document SYSTEM
"http://uadb.edu.sn/document.dtd">`

Structure physique : DTD

- `<!DOCTYPE document (PUBLIC "identifiant_public" "url"?)>`
- PUBLIC est utilisé lorsque la DTD est une norme ou qu'elle est enregistrée sous forme de norme ISO par l'auteur

Structure physique : DTD

● DTD externe

- Les déclarations sont placés dans un fichier séparé portant l'extension .dtd

<!DOCTYPE document (SYSTEM "uri")>

- L'attribut **standalone** a la valeur **"no"**

<?xml version="1.0" standalone="no" >

**<!DOCTYPE document SYSTEM
"http://ucad.sn/document.dtd">**

<document > ... </document >

- un chemin relatif :

<?xml version="1.0" standalone="no" >

<!DOCTYPE document SYSTEM "document.dtd">

<document > ... </document >

Contrainte sur la DTD EXTERNE

- Il peut contenir un prologue
- Pas de référence à une DTD
- Il doit être bien formé

Structure physique : DTD

- Déclaration de listes d'attributs
 - `<!ATTLIST Nom_élément Nom_attribut type_attribut défaut>`
 - `<!ATTLIST document nd (1|2|3) "1">`
- Type d'attributs :
 - CDATA : chaîne de caractères prise telle quelle
 - ID ou IDREF : renvoi dans le document
 - ENTITY ou ENTITIES : entité externe non XML
 - NMTOKEN (s): noms symboliques formés de caractères alphanumériques sans espace (plusieurs NMTOKEN)

Structure physique : DTD

- Déclaration d'un élément :
- `<!ELEMENT balise valeur>`
- Décrit une balise **balise** qui fera partie du vocabulaire
- **Ordre spécifié :**
- `<!ELEMENT balise (val1, val2, val3)>`
- **Ordre libre :**
- `<!ELEMENT balise (val1 | val2 | val3)+>`
- **Liste de choix:**
- `<!ELEMENT balise (val1 | val2 | val3)>`
- Contenu textuel déclaré comme PCDATA (parseable character data)

Structure physique : DTD

- Opérateurs d'occurrence

- **Notations**

- (a, b) séquence
- (a | b) liste de choix
- a? élément optionnel [0,1]
- a* élément répétitif [0,N]
- a+ élément répétitif [1,N]

Exemples

(nom, prenom, rue, ville)

(oui | non)

(nom, prenom?, rue, ville)

(produit*, client)

(produit*, vendeur+)

Structure physique : DTD

- Valeur par défaut des attributs:
 - **#REQUIRED** : attribut obligatoirement présent et valeur spécifié par le créateur de l'instance
 - **#IMPLIED** : présence de l'attribut facultative
 - **#FIXED** "Valeur" : l'attribut prend toujours cette valeur

Structure physique : DTD

- Données dans un élément : simple
 - `<!ELEMENT Donnees (#PCDATA)>`
 - les données sont constituées par un flot de caractères
- Modèle mixte : complexe
 - `<!ELEMENT mixte (#PCDATA | val1 | val2)*>`
 - dans cet exemple l'élément mixte est composé de données et d'éléments

Quelques exemples

- Contenu libre :
 - <!ELEMENT libre ANY>
- Élément vide :
 - <!ELEMENT vide EMPTY>
- Attributs pour un élément :
 - <!ATTLIST balise [attribut type #mode [valeur]]>
- Définition de la liste des attributs pour une balise
 - <!ATTLIST **enseignant** **nom** CDATA #REQUIRED **prenom** CDATA #IMPLIED>
 - <!ATTLIST adresse ville CDATA #FIXED "Dakar">

Quelques exemples

- Liens hypertextuels internes : ID ou IDREF
- Dans la DTD
 - `<!ELEMENT SECTION (#PCDATA|xref)*>`
 - `<!ATTLIST SECTION TARGET ID #IMPLIED>`
 - `<!ELEMENT xref EMPTY>`
 - `<!ATTLIST xref ref IDREF #REQUIRED>`
- Dans l'instance
 - `<SECTION TARGET="cible"> contenu </SECTION>`
 - `<SECTION>` référence à la section
 - `<xref ref="cible"/>`
 - `</SECTION>`

Structure physique : Une DTD pour un Address Book

```
<?xml version="1.0" encoding="UTF-8"?>
<!ELEMENT addressBook (person)+>
  <!ELEMENT person (name, email*, link)>
  <!ATTLIST person id ID #REQUIRED
                  gender (male|female) #IMPLIED>
  <!ELEMENT name (#PCDATA|family|given)*>
  <!ELEMENT family (#PCDATA)>
  <!ELEMENT given (#PCDATA)>
  <!ELEMENT email (#PCDATA)>
  <!ELEMENT link EMPTY>
  <!ATTLIST link manager IDREF #IMPLIED subordinates IDREFS
#IMPLIED>
```

Exemple d'un XML valide par rapport aux règles dans la DTD précédente

```
<!DOCTYPE addressBook SYSTEM "ab.dtd">
<addressBook>
  <person id="B.WALLACE" gender="male">
    <name>
      <family>Wallace</family> <given>Bob</given>
    </name>
    <email>bwallace@megacorp.com</email>
    <link manager="C.TUTTLE"/>
  </person>
  <person id="C.TUTTLE" gender="female">
    <name>
      <family>Tuttle</family> <given>Claire</given>
    </name>
    <email>ctuttle@megacorp.com</email>
    <link subordinates="B.WALLACE"/>
  </person>
</addressBook>
```

Exemple DTD

- Supposons, La description des livres d'une librairie

- Stocker des informations sur titre, auteur, éditeur, prix
- C'est possible d'avoir plusieurs auteurs pour un livre
- Le prix est optionnel
- Les prix seront classés par catégorie
- cat1 pour les livres dont le prix est inférieur à 20€
- cat2 pour les livres dont le prix est entre 20€ et 40€
- cat3 pour les livres dont le prix est supérieur à 40€

Définir en <cat1></cat1>, <cat2></cat2>, <cat3></cat3>

Exemple DTD

- Nœuds racine est **librairie**
- `<!DOCTYPE librairie [
... instructions ...`
- `]>`

Exemple DTD

- Dans notre librairie, on peut avoir 0 ou plusieurs livres
- `<!DOCTYPE librairie [
 <!ELEMENT librairie (livre*)>
]>`

Exemple DTD

- L'information d'un livre (titre, auteur, éditeur, prix)
- `<!DOCTYPE librairie [
 <!ELEMENT librairie (livre*)>
 <!ELEMENT livre(titre, auteur, éditeur,
 prix)>
]>`

Exemple DTD

- Un livre peut avoir un ou plusieurs auteurs
- `<!DOCTYPE librairie [
 <!ELEMENT librairie (livre*)>
 <!ELEMENT livre(titre, auteur+, éditeur,
 prix)>
]>`

Exemple DTD

- Le prix d'un livre est optionnel
- `<!DOCTYPE librairie [
 <!ELEMENT librairie (livre*)>
 <!ELEMENT livre(titre, auteur+, éditeur,
 prix?)>
]>`

Exemple DTD

- Titre, auteur et éditeur sont stockés comme chaîne de caractère.
- `<!DOCTYPE librairie [
 <!ELEMENT librairie (livre*)>
 <!ELEMENT livre(titre, auteur+, éditeur, prix?)>
 <!ELEMENT titre (#PCDATA)>
 <!ELEMENT auteur (#PCDATA)>
 <!ELEMENT éditeur (#PCDATA)>
]>`

Exemple DTD

- Prix sont stockés soit cat1, cat2 ou cat3
- `<!DOCTYPE librairie [
 <!ELEMENT librairie (livre*)>
 <!ELEMENT livre(titre, auteur+, éditeur, prix?)>
 <!ELEMENT titre (#PCDATA)>
 <!ELEMENT auteur (#PCDATA)>
 <!ELEMENT éditeur (#PCDATA)>
 <!ELEMENT prix (cat1 |cat2 | cat3)>
]>`

Exemple DTD

- Cat1, cat2, cat3 sont des éléments qui sont valeurs
- ```
<!DOCTYPE librairie [
 <!ELEMENT librairie (livre*)>
 <!ELEMENT livre(titre, auteur+, éditeur, prix?)>
 <!ELEMENT titre (#PCDATA)>
 <!ELEMENT auteur (#PCDATA)>
 <!ELEMENT éditeur (#PCDATA)>
 <!ELEMENT prix (cat1 |cat2 | cat3)>
 <!ELEMENT cat1 EMPTY>
 <!ELEMENT cat2 EMPTY>
 <!ELEMENT cat3 EMPTY>
```

● ]>

## DTD avec attribut

---

- Le prix d'un livre est **optionnel** et **c'est l'attribut** de l'élément livre qui a des valeurs, soit **cat1**, **cat2** ou **cat 3**
- ```
<!DOCTYPE librairie [  
  <!ELEMENT librairie (livre*)>  
  <!ELEMENT livre(titre, auteur+, éditeur)>  
  <!ATTLIST livre prix(cat1|cat2|cat3) #IMPLIED>  
]>
```